


LLM Fine-Tuning

with. LoRA



TEAM: 땡콩



1. 데이터셋

[knkarthick/SAMSum]

Input: Raw Dialogue (비정형 데이터)

Tim: Hi, what's up?
Kim: Bad mood tbh, I was going to do lots of stuff but ended up procrastinating
Tim: What did you plan on doing?
Kim: Oh you know, uni stuff and unfucking my room
Kim: Maybe tomorrow I'll move my ass and do everything
Kim: We were going to defrost a fridge so instead of shopping I'll eat some defrosted veggies
Tim: For doing stuff I recommend Pomodoro technique where u use breaks for doing chores
Tim: It really helps

Output: Summary (구조화된 요약)

Kim may try the pomodoro technique recommended by Tim to get more stuff done.

Task : 대화 요약
Training : 14.7K
Validation : 818
Test : 819

● Training

● Validation

● Test

2. 하이퍼파라미터

Optimizer: AdamW

Schduler: Linear

Warmup ratio: 0.1

Batch size: 64

Epochs: 2

Learning rate: $2e-4$

Dropout: 0.1

Max input length: 512

Max output length: 128


3. 평가지표

평가지표	산출방법
ROUGE-1	단어(1-gram) 겹침
ROUGE-2	연속된 두 단어(2-gram) 겹침
ROUGE-L	단어 순서를 유지하면서 가장 길게 공통되는 부분(LCS)
ROUGE-Lsum	요약 전체 단위에서의 LCS
BERTScore	의미적 유사도

4. 실험 설계

	# of Trainable Parameters = 18M						
Weight Type Rank r	W_q 8	W_k 8	W_v 8	W_o 8	W_q, W_k 4	W_q, W_v 4	W_q, W_k, W_v, W_o 2
WikiSQL ($\pm 0.5\%$)	70.4	70.0	73.0	73.2	71.4	73.7	73.7
MultiNLI ($\pm 0.1\%$)	91.0	90.8	91.0	91.3	91.3	91.3	91.7

어느 레이어에 LoRA를 넣어야 효율적인가?



5. 실험 결과

Layer	Rank	Alpha	ROUGE-1	ROUGE-2	ROUGE-L	ROUGE-Lsum	BERTScore	Params
Baseline	x	x	26.6	10.6	20.8	22.2	81.2	x
Q	8	16	51.6	27.8	43.4	43.4	90.8	2.1M
K	8	16	47.8	24.2	39.4	39.4	89.4	1.3M
V	8	16	52.5	28.0	44.2	44.2	91.2	1.3M
O	8	16	52.4	28.1	43.9	44.0	90.4	2.1M
Q, K	4	8	50.9	27.3	42.8	42.8	89.9	1.7M
Q, V	4	8	52.2	28.1	43.5	43.5	90.6	1.7M
Q, K, V, O	2	4	52.0	28.2	43.7	43.7	90.8	1.7M

6. GPT-3와의 결과 비교

Layer	Params	R1/R2/RL
Q	2.1M	51.6/27.8/43.4
K	1.3M	47.8/24.2/39.4
V	1.3M	52.5/28.0/44.2
O	2.1M	52.4/28.1/43.9
Q, K	1.7M	50.9/27.3/42.8
Q, V	1.7M	52.2/ 28.1 /43.5
Q, K, V, O	1.7M	52.0/ 28.2 /43.7

Model&Method	# Trainable Parameters	SAMSum
		R1/R2/RL
GPT-3 (FT)	175,255.8M	52.0/28.0/44.5
GPT-3 (LoRA)	4.7M	53.8/29.8/45.9
GPT-3 (LoRA)	37.7M	53.4/29.2/45.1

7. 추가 실험1(상) - V, O

Layer	Rank	Alpha	ROUGE-1	ROUGE-2	ROUGE-L	ROUGE-Lsum	BERTScore	Params
Q	8	16	51.6	27.8	43.4	43.4	90.8	2.1M
K	8	16	47.8	24.2	39.4	39.4	89.4	1.3M
V	8	16	52.5	28.0	44.2	44.2	91.2	1.3M
O	8	16	52.4	28.1	43.9	44.0	90.4	2.1M
Q, K	4	8	50.9	27.3	42.8	42.8	89.9	1.7M
Q, V	4	8	52.2	28.1	43.5	43.5	90.6	1.7M
Q, K, V, O	2	4	52.0	28.2	43.7	43.7	90.8	1.7M
V, O	4	8	52.9	28.7	44.3	44.3	91.2	1.7M

7. 추가 실험1(하) - Rank 증가

Layer	Rank	Alpha	ROUGE-1	ROUGE-2	ROUGE-L	ROUGE-Lsum	BERTScore	Params
V, O	4	8	52.9	28.7	44.3	44.3	91.2	1.7M
V, O	8	16	53.0	28.7	44.5	44.5	91.1	3.4M
V, O	16	32	53.0	28.6	44.5	44.4	91	6.8M

일정 수준이상으로 Rank를 늘리는 것은 의미 없음

7. 추가 실험2 - MLP Layer에 추가

Down_proj: FFN의 출력을 hidden dim으로 압축
→ 출력 품질에 좋은 영향을 줄 것이다!

Layer	Rank	Alpha	ROUGE-1	ROUGE-2	ROUGE-L	ROUGE-Lsum	BERTScore	Params
V, D	4	8	52.9	28.9	44.5	44.5	91.0	3.0M

V, O	4	8	52.9	28.7	44.3	44.3	91.2	1.7M
V	8	16	52.5	28.0	44.2	44.2	91.2	1.3M

ROUGEScore는 약간의 향상
BUT. BERTScore는 하락

Parameter 수가 매우 증가하였지만
효율성이 좋지 않음

8. 번외

Scale: x4

Layer	Rank	Alpha	ROUGE-1	ROUGE-2	ROUGE-L	ROUGE-Lsum	BERTScore
Q, V	4	8	52.1	28.1	43.5	43.5	90.6
Q, V	4	16	52.4	28.3	43.9	43.9	91.0

모든 지표 성능 향상

Scale: x8

Layer	Rank	Alpha	ROUGE-1	ROUGE-2	ROUGE-L	ROUGE-Lsum	BERTScore
Q, K, V, O	2	4	52.9	28.7	44.3	44.3	90.8
Q, K, V, O	2	16	53.1	29.3	44.8	44.8	90.8

ROUGE 향상, BERTScore 그대로

Layer	Rank	Alpha	ROUGE-1	ROUGE-2	ROUGE-L	ROUGE-Lsum	BERTScore	Params	Series
Base	-	-	26.6	10.6	20.8	22.2	81.2	-	Base
Q	8	16	51.6	27.8	43.4	43.4	90.8	2.1M	Base
K	8	16	47.8	24.2	39.4	39.4	89.4	1.3M	Base
V	8	16	52.5	28.0	44.2	44.2	91.2	1.3M	Base
O	8	16	52.4	28.1	43.9	44.0	90.4	2.1M	Base
Q, K	4	8	50.9	27.3	42.8	42.8	89.9	1.7M	Base
Q, V	4	8	52.2	28.1	43.5	43.5	90.6	1.7M	Base
Q, K, V, O	2	4	52.0	28.2	43.7	43.7	90.8	1.7M	Base
V, O	4	8	52.9	28.7	44.3	44.3	91.2	1.7M	추가 실험1
V, O	8	16	53.1	28.7	44.5	44.5	91.1	3.4M	추가 실험1
V, O	16	32	53.0	28.6	44.5	44.4	91.0	6.8M	추가 실험1
V, D	4	8	52.9	28.9	44.5	44.5	91.0	3.0M	추가 실험2
Q, K, V, O	2	16	53.1	29.2	44.8	44.8	90.8	1.7M	번외
Q, V	4	16	52.4	28.3	43.9	43.9	91.0	17M	번외

9. 결론 및 후속연구

- Rank를 늘려도 성능이 계속 오르지 않음
- Task에 따라 중요한 layer가 다름
- 요약Task는 V에 적용하는 경우 가장 높은 성능
- → 선택된 정보를 어떻게 만들어내느냐가 성능을 좌우
- rank를 크게 늘리는 대신 alpha를 조절하는 것이 파라미터 효율적
- → x4: 무조건 시도 / x8: 비교해볼만함
- MLP layer에 대한 확장은 의미 표현 개선보다는 파라미터 증가로 이어지며,
- 효율성 측면에서 불리함

후속 연구

- “다른 데이터셋에 대한 실험을 통하여 요약 task에서는 V가 중요하다”를 검증
- Transformer 구조에 대하여 자세하게 공부

Thank You